Спиновые стекла, как модель нейронных сетей.

Акинжала Родион, Ибрагимова Ксения

9 марта 2026 г.

Введение

Спиновые стёкла: от одномерной модели Изинга к многослойным системам

Спин стекло — это система, в которой спины (магнитные моменты атомов) взаимодействуют через беспорядочно распределённые и конкурентные взаимодействия. Такое распределение приводит к состоянию фрустрации, при котором невозможно минимизировать энергию всех взаимодействий одновременно. Это создаёт сложный энергетический ландшафт с множеством локальных минимумов.

Ключевые характеристики спинового стекла

- **Фрустрация**: Возникает из-за конкуренции между ферромагнитными и антиферромагнитными взаимодействиями, что делает невозможным удовлетворение всех взаимодействий одновременно.
- **Беспорядок**: Взаимодействия между спинами J_{ij} имеют случайные значения, что разрушает дальний магнитный порядок.
- **Сложный энергетический ландшафт**: Множество локальных минимумов энергии разделены высокими барьерами.
- **Квазиклассическое приближение**: Система может быть описана в рамках классической статистической механики. Гамильтониан имеет вид:

$$\mathcal{H} = -\frac{1}{2}\sum_{i,j} J_{ij} S_i S_j, \tag{1}$$

  где $S_i = \pm 1$ — классические спины, а J_{ij} — взаимодействия.
- **Примеры материалов**: Спиновые стёкла реализуются в системах, таких как CuMn, AuFe, $\mathrm{Eu}_x\mathrm{Sr}_{1-x}\mathrm{S}$, где беспорядочные взаимодействия достигаются путём легирования.

Одномерная модель Изинга

Одной из первых моделей, описывающих спиновые системы, является одномерная модель Изинга. Эта модель представляет собой систему спинов, расположенных вдоль одной оси,

где каждый спин может находиться в одном из двух состояний ($+1$ или -1). Взаимодействие ограничено ближайшими соседями, и гамильтониан системы задаётся как:

$$\mathcal{H} = -\sum_i J S_i S_{i+1}, \tag{2}$$

где J — константа взаимодействия между соседними спинами, S_i — состояние i-го спина. Одномерная модель была решена аналитически, что сделало её важным инструментом для изучения фазовых переходов в упорядоченных системах.

Фрактальное дерево состояний

В 1980–1990-х годах была предложена концепция фрактального дерева состояний в одномерной модели Изинга с взаимодействиями большого радиуса. Это расширение вводило дальнодействующие взаимодействия, существенно усложняя энергетический ландшафт системы. Фрактальная структура состояний приближала модель к реальным спиновым стёклам, где беспорядок и фрустрация играют ключевую роль.

Многослойные системы

Расширение спиновых моделей на многослойные системы стало естественным развитием исследований. Такие модели учитывают иерархические взаимодействия и сложные структуры.

Многослойная модель Шеррингтона-Киркпатрика (СК-модель) представляет собой обобщение классической модели спинового стекла. Детальное описание модели представлено в следующей части.

Связь с нейронными сетями

Нейронные сети имеют тесную связь со спиновыми системами. Такие архитектуры, как многослойные перцептроны, ограниченные машины Больцмана и сети Хопфилда, можно интерпретировать через взаимодействия спинов.

- **Многослойные перцептроны**: аналог взаимодействий между слоями в СК-модели.
- **Ограниченные машины Больцмана**: вероятностное описание состояний, схожее с термодинамическими моделями.
- **Сети Хопфилда**: двусторонние взаимодействия между нейронами, аналогичные симметричной СК-модели.

В таких системах используются методы анализа, включая уравнения Таулеса-Андресона-Палмера (ТАР), которые позволяют описывать сложные энергетические ландшафты и фазовые переходы. Аналогично, обучение нейронных сетей может рассматриваться как минимизация энергии, связанной с их параметрами и переход в стабильные и метастабильные состояния.

Модель

Считаем диполи разбросаны по слоям.

Поле, которое создает один диполь:

$$\mathbf{B} = \left[\frac{3(\mathbf{m}\cdot\mathbf{r})\mathbf{r}}{r^5} - \frac{\mathbf{m}}{r^3}\right], \tag{3}$$

В нашей модели учитываем взаимодействие только соседних слоев. Будем проходить с верхнего слоя к нижнему и смотреть как установятся диполи. Под функцией активацией в этой работе будем подразумевать в какую сторону повернется определеенный диполь в проекции на заданную ось, после того как провзаимодействует со всеми соседними диполями. И в итоге мы получим +1 или -1 в зависимости от проекции суперпозипции B на ось x (т.к энергия магнитного диполя $U = -\mathbf{m}\cdot\mathbf{B}$, то он должен быть ориентирован по направлению B в положении равновесия)

Тогда:

Под значением спина $\sigma_i = \pm 1$ будем подразумевать знак проекции m на ось x

Под значением веса J_{ij} — модуль энергии взаимодействия между спинами σ_i и σ_j

Под смещения (bias) b_i — внешние магнитные поля (но в этой модели мы не рассматриваем их).

Перед началом обучения веса нейронной сети (J_{ij}) независимо и нормально распределены так, чтобы сохранять величину дисперсии активаций в прямом проходе. Для этого используется нормальная инициализация Кайминга (Kaiming normal initialization).

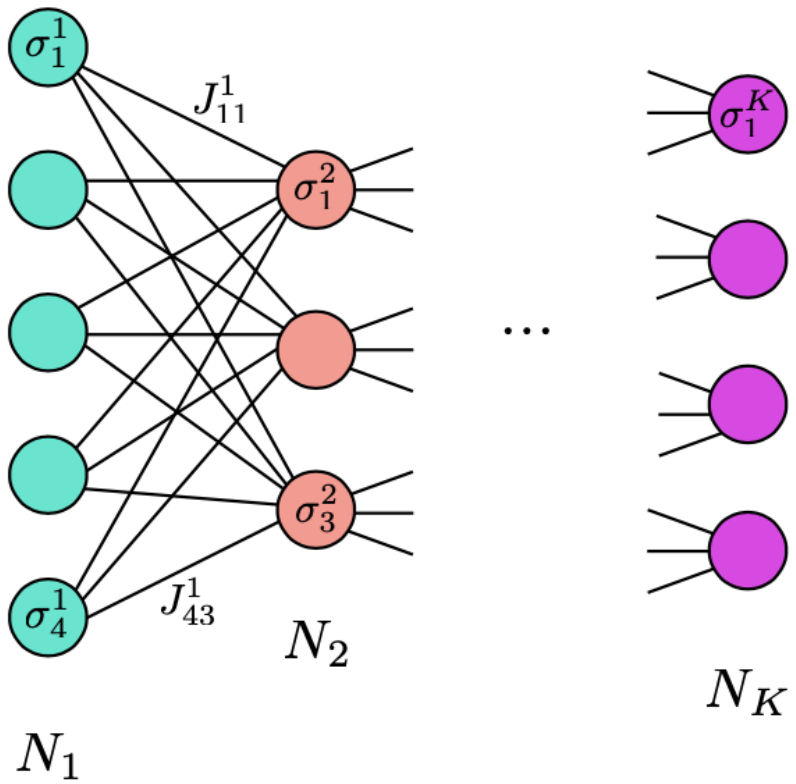

Рис. 1: Схема стекла модели MSK

Рассмотрим нейронную сеть с $L+1$ слоями, пронумерованными от 0 до L. При сопоставлении нейронов сети со спинами Изинга ($\sigma_i = \pm 1$) и использовании весов в качестве взаи-

модействий между спинами, получаем многослойную модель Шеррингтона-Киркпатрика (MSK), определяемую следующим гамильтонианом:

$$H_{\mathrm{MSK}}(\sigma) = -\sum_{k=1}^{L}\sum_{i=1}^{N_{k-1}}\sum_{j=1}^{N_k} J_{ij}^{(k)}\sigma_i^{(k-1)}\sigma_j^{(k)},$$

где каждый $J_{ij}^{(k)}$ независимо взят из распределения $\mathcal{N}(0, C_k/N_{k-1})$. Для больших N_k система демонстрирует высокий уровень координации между спинами, что делает методы теории среднего поля применимыми.

В случае глубокой нейронной сети гамильтониан может быть упрощён в следующей форме:

$$H_{\mathrm{MSK}}(\sigma) = -\frac{1}{2}\sum_{i,j=1}^{N} J_{ij}\sigma_i\sigma_j,$$

где $N = \sum_{k=0}^{L} N_k$ — общее число магнитных моментов, а матрица взаимодействий J имеет блочно-трёхдиагональную структуру:

$$J = \begin{pmatrix} 0 & J^{(1)} & 0 & \cdots & 0 \\ (J^{(1)})^T & 0 & J^{(2)} & \cdots & 0 \\ 0 & (J^{(2)})^T & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & J^{(L)} \\ 0 & 0 & 0 & (J^{(L)})^T & 0 \end{pmatrix}.$$

Система изначально находится в парамагнитной фазе при высокой температуре. При снижении температуры появляется стекловидное состояние, характеризуемое нарушением симметрии реплик. Мы вычисляем критическую температуру T_c, при которой происходит этот фазовый переход.

Начальные условия и критическая температура

На начальном этапе обучения ($t = 0$) веса сети W_{ij} задаются случайно, что соответствует случайным взаимодействиям J_{ij} в модели спинового стекла. Анализ показывает, что такая система демонстрирует фазовый переход в стекловидное состояние с нарушением симметрии реплик. Критическая температура T_c вычисляется аналитически.

Во время обучения мы численно определяем T_c как температуру, при которой начинают появляться нетривиальные решения уравнений TAP. Мы наблюдаем, что T_c изменяется по степенному закону:

$$T_c(t) \propto t^{\alpha},$$

где α зависит от скорости обучения стекла. В ходе обучения мы наблюдаем, как температура фазового перехода растет степенным образом и система переходит к фазе с "скрытым порядком".

Фазовая диаграмма

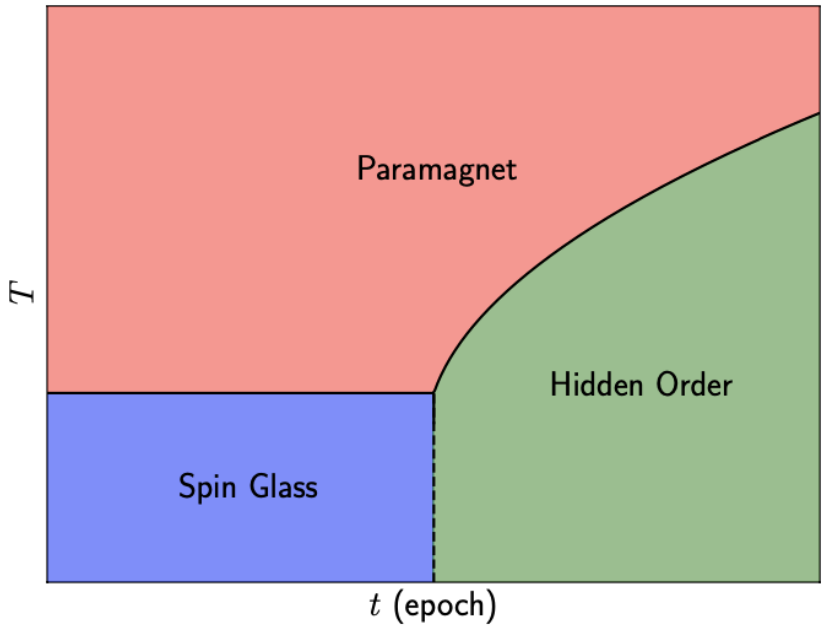

Рис. 2: Фазы системы

Парамагнитная фаза ($T > T_c$): При высокой температуре система спинового стекла находится в парамагнитной фазе.

-Спины ориентированы хаотично, их корреляции минимальны, и система свободно "прыгает"между различными конфигурациями.

-Это соответствует обучению нейронной сети на начальных этапах, когда веса изменяются стохастически и модель исследует глобальный ландшафт функции потерь.

-Здесь энергетический ландшафт гладкий, и барьеры между минимумами легко преодолеваются.

Фазовый переход ($T \approx T_c$): Соответствует фазовому переходу, когда веса начинают стабилизироваться.

-В обучении сети это момент, когда модель перестает случайно исследовать и сосредотачивается на одной или нескольких "энергетических ямах"(локальных минимумах).

Спиновое стекло ($T < T_c$): Когда температура снижается ниже критической, система переходит в фазу спинового стекла. В этой фазе:

-Система застревает в локальных минимумах энергии, соответствующих сложному ландшафту с множеством минимумов.

-Конфигурации спинов (или весов в нейронной сети) становятся коррелированными, и система демонстрирует долговременную память о предыдущих состояниях.

-В обучении нейронной сети это соответствует этапу, когда веса сети стабилизируются в одной из "энергетических ям и модель начинает сосредотачиваться на локальной оптимизации.

Отжиг системы

Чтобы продемонстрировать как меняется система на определенно эпохе, будем запускать отжиг системы с температуры в несколько раз выше критической до нуля, и рассматривать, как меняется картина слоя. Будем делать компьютерное моделирование динамического процесса односпиновых переворотов в рамках статистического метода Монте-Карло.

Приведем наиболее общую форму алгоритма Метрополиса на примере системы спинов:

- Производим случайное пробное изменение в начальной конфигурации. Например, выбираем случайным образом какой-нибудь спин и пробуем его опрокинуть. Или выбираем случайную частицу и пробуем переместить ее на случайное расстояние.

-Вычисляем $E_{\text{нов}}$,,.

-Если $E_{\text{нов}} < E_{\text{стар}}$, то новая конфигурация принимается автоматически.

-Если $E_{\text{нов}} > E_{\text{стар}}$, то новая конфигурация принимается с вероятностью $e^{-\frac{\Delta E}{kT}}$. Для этого генерируется случайное число r в интервале $[0, 1]$. Если $r < e^{-\frac{\Delta E}{kT}}$, конфигурация принимается, иначе — отклоняется.

Повторяем шаги много раз для получения достаточного числа конфигураций. Далее уменьшаем температуру на некоторую величину и совершаем все предыдущие шаги. Будем выводить изображение слоя при охлаждении системы, мы должы увидеть как при достижении температуры ниже критической картина перестает быть хаотичной.

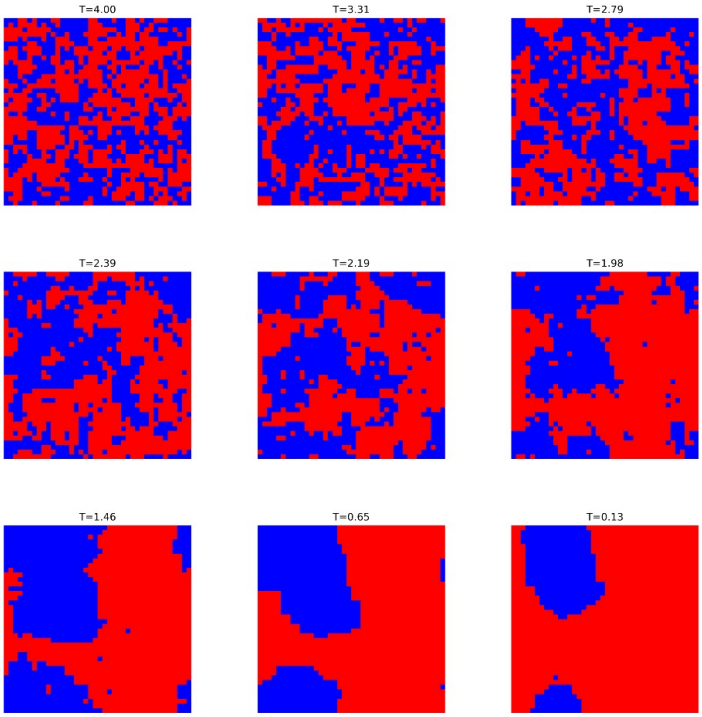

Первые изображения демонстрируют парамагнетную фазу при высокой температуре, как можно заметить: система свободно меняет конфигурацию. Далее при температуре около 2.19K происходит фазовый переход, и при более низкой температуре система стабилизируется.

Уравнения ТАП (Thouless-Anderson-Palmer)

До сих пор в нашем анализе многослойной модели Шеррингтона-Киркпатрика (MSK) использовалось усреднение по беспорядку. Это значит, что рассматривались ансамбли систем с независимыми случайно распределёнными связями. Однако, если связи определены некоторой процедурой обучения, такой ансамбль недоступен для усреднения. Вместо этого можно использовать подход ТАП (Thouless-Anderson-Palmer), позволяющий анализировать ландшафт энергии для конкретного случая.

Свободная энергия в теории среднего поля для системы с парными взаимодействиями между спинами задаётся уравнением:

$$\begin{aligned} F = -\frac{1}{2}\sum_{ij} J_{ij} m_i m_j - \frac{1}{4}\beta \sum_{ij} J_{ij}^2 (1-m_i^2)(1-m_j^2) \\ +\frac{1}{2}T\sum_i \left\{ (1+m_i)\log\left[\frac{1}{2}(1+m_i)\right] + (1-m_i)\log\left[\frac{1}{2}(1-m_i)\right] \right\}, \end{aligned} \tag{4}$$

где:

- $m_i = \langle \sigma_i \rangle$ — средние значения спинов;
- J_{ij} — матрица взаимодействий между спинами;
- $\beta = 1/T$ — обратная температура;
- T — температура системы.

Первое слагаемое в этом выражении соответствует стандартной свободной энергии модели Кюри-Вайса. Второе, так называемый терм Онсагера, корректирует вклад эффективного поля, чтобы учесть, что спин не влияет на своё собственное поле. Третье слагаемое представляет энтропийный вклад в свободную энергию, который возникает из-за бинарной природы спинов.

Минимизируя по m_i, можно получить уравнения ТАП:

$$\tanh^{-1}(m_i) = \beta \sum_j J_{ij} m_j - \beta^2 \sum_j J_{ij}^2 (1-m_j^2) m_i. \tag{5}$$

Эти уравнения описывают фиксированные точки свободной энергии системы. Их решение определяет состояние спинового стекла в зависимости от температуры.

Температурные режимы

Состояние системы зависит от температуры:

- **При температуре выше критической ($T > T_c$)**: Все $m_i = 0$, и система находится в парамагнитном состоянии, где спины распределены хаотически.
- **При температуре ниже критической ($T < T_c$)**: Уравнения $m_i \neq 0$ дают ненулевые значения, что соответствует фазе спинового стекла с частично упорядоченными состояниями.
- **При температуре немного ниже критической**: Средние значения m_i малы, что позволяет линеаризовать уравнения ТАП:

$$m_i = \beta \sum_j J_{ij} m_j - \beta^2 \sum_j J_{ij}^2 m_i. \tag{6}$$

Или, в матричном виде:

$$(I_N - M)m = 0, \tag{7}$$

где $M_{ij} = \beta J_{ij} - \delta_{ij}\beta^2 \sum_\ell J_{i\ell}^2$.

Минимальное собственное значение матрицы $I_N - M$ позволяет найти критическую температуру T_c. При T_c минимальное собственное значение впервые становится равным нулю, что соответствует фазовому переходу из парамагнитного состояния в фазу спинового стекла.

Алгоритм вычисления критической температуры

1. **Формируем матрицу M:** Для заданных весов J_{ij} элементы матрицы задаются как:

$$M_{ij} = \beta J_{ij} - \delta_{ij}\beta^2 \sum_\ell J_{i\ell}^2.$$

   Здесь используется блочно-трёхдиагональная структура M, что упрощает вычисления для многослойных сетей.

2. **Диагонализация матрицы M:** Рассчитываем минимальное собственное значение $\lambda_{\min}$ для матрицы $I_N - M$ при различных значениях $\beta = 1/T$.

3. **Поиск температуры T_c:** Критическая температура соответствует β_c, при котором $\lambda_{\min}$ впервые становится нулевым:

$$T_c = \frac{1}{\beta_c}.$$

График $\lambda_{\min}$ от β :

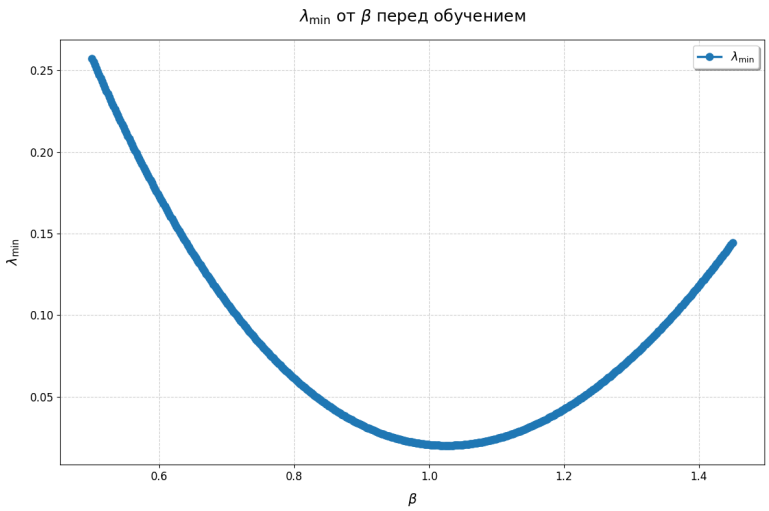

Рис. 3: $\lambda_{\min}$ от β перед обучением.

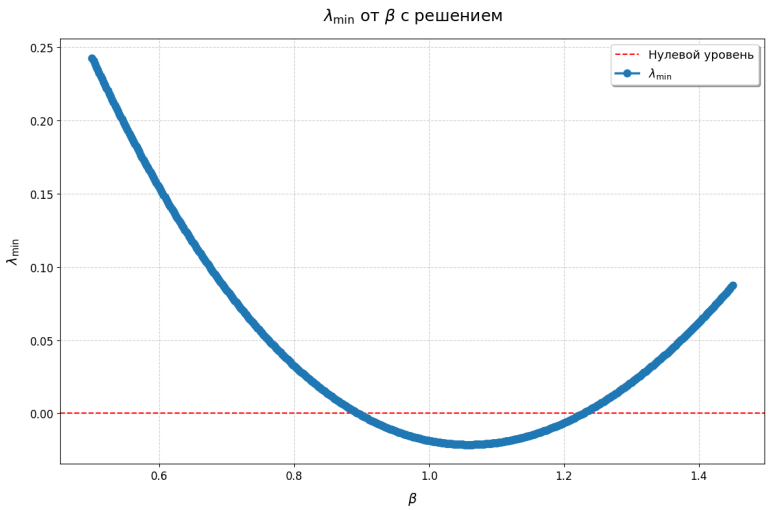

Рис. 4: $\lambda_{\min}$ от β в процессе обучения.

Процесс тренировки

Градиентный спуск (SGD) используется для минимизации функции потерь, что позволяет постепенно улучшать предсказания спинновго стекла. В физическом смысле процесс градиентного спуска напоминает "охлаждение"системы:

- В начале обучения (высокие значения потерь) система имеет высокую "температуру что соответствует неупорядоченному состоянию спинов. Так, на фазовой диаграмме, это состояние отвечает парамагнетику
- По мере уменьшения функции потерь "температура"системы падает, что приводит к упорядочиванию весов W_{ij} и формированию устойчивой конфигурации.
- Этот процесс аналогичен методу отжига в физике, где система медленно охлаждается, чтобы достичь глобального минимума энергии. При этом с каждой эпохой точность модели увеличивается

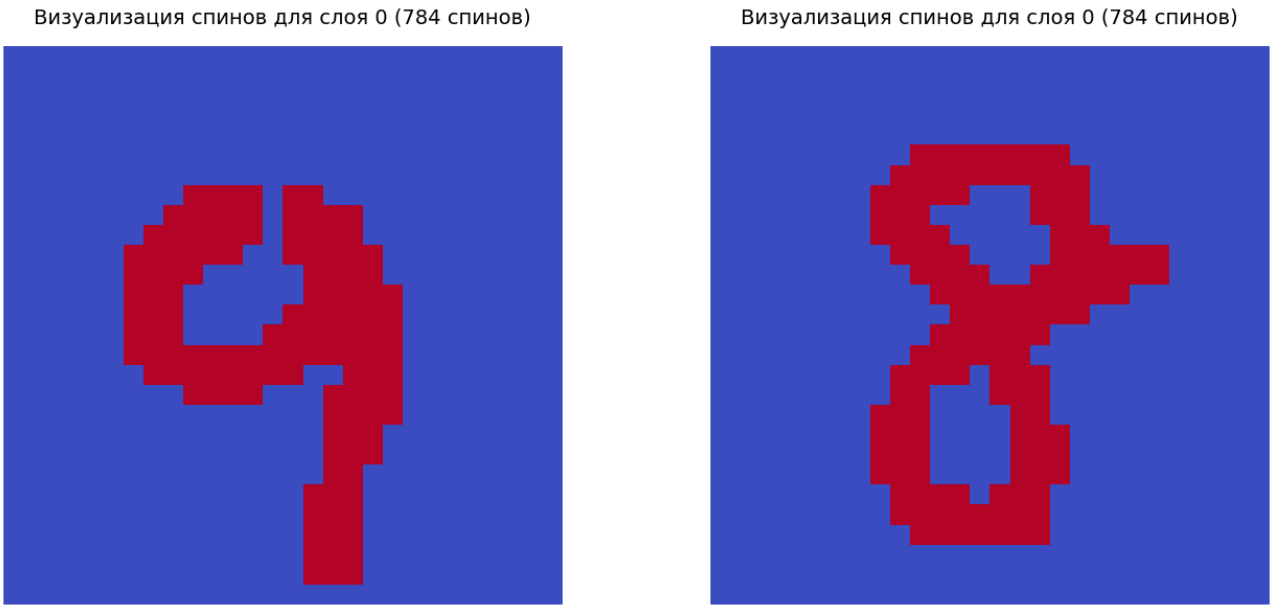

Рис. 5: Инициализация спинов на входном наборе

Прямой проход (Forward Pass)

Прямой проход включает следующие этапы:

- Для каждого скрытого слоя рассчитывается локальное поле:

$$z = \mathbf{a} \cdot \mathbf{W}, \tag{8}$$

  где $\mathbf{a}$ — активации текущего слоя, $\mathbf{W}$ — матрица весов.

- Активации вычисляются с помощью step-функции:

$$a_i = \begin{cases} +1, & \text{если } z_i \geq 0, \\ -1, & \text{если } z_i < 0. \end{cases} \tag{9}$$

Обратное распространение ошибки (Backward Pass)

Обратное распространение ошибки (Backpropagation) представляет собой процесс вычисления градиентов функции потерь по параметрам модели, что позволяет оптимизировать её обучение. В данном случае используется стохастический градиентный спуск (SGD) с моментом. Рассмотрим основные этапы обратного распространения:

Градиент на выходном слое

Градиент функции потерь на выходном слое рассчитывается как разность между предсказанными значениями модели $\hat{y}$ и истинными метками y:

$$\delta^{(L)} = \hat{y} - y, \tag{10}$$

где:

- $\hat{y}$ — предсказания модели на выходном слое;
- y — истинные метки, имеют размерность как у последнего слоя.

Этот градиент является начальной точкой для обратного распространения, так как он показывает, насколько предсказания отклоняются от истинных значений.

Градиенты для скрытых слоёв

Для скрытых слоёв градиенты вычисляются итеративно, начиная с выхода модели и двигаясь в обратном направлении. Градиент на слое l выражается через градиенты на следующем слое $l+1$:

$$\delta^{(l)} = (\delta^{(l+1)} \cdot W^{(l+1)}) \cdot h'(z^{(l)}), \tag{11}$$

где:

- $\delta^{(l+1)}$ — градиенты ошибки следующего слоя;
- $W^{(l+1)}$ — веса, связывающие слой l со слоем $l+1$;
- $h'(z^{(l)})$ — производная функции активации слоя l.

В качестве функции активации используется бинаризация, которая является недифференцируемой. Для её аппроксимации применяется метод Straight-Through Estimator (STE), в котором производная принимается равной 1 в диапазоне $[-1, 1]$:

$$h'(z) = \begin{cases} 1, & \text{если } |z| < 1, \\ 0, & \text{иначе.} \end{cases} \tag{12}$$

Этот метод позволяет эффективно распространять градиенты через бинаризованные слои.

Градиенты весов

После вычисления градиентов по активациям для каждого слоя, градиенты для весов рассчитываются по формуле:

$$\frac{\partial L}{\partial W_{ij}} = a_i \cdot \delta_j, \tag{13}$$

где:

- a_i — активация нейрона i текущего слоя;
- δ_j — градиент ошибки нейрона j следующего слоя.

Эта формула соответствует правилу цепочки, где изменение весов пропорционально входным активациям и ошибке следующего слоя. Градиенты для всех весов на данном слое суммируются по всем образцам в батче, после чего усредняются для стабильности обновлений.

Обновление весов

После вычисления градиентов веса обновляются с использованием правила градиентного спуска с моментом:

$$v_t = \mu v_{t-1} - \eta \nabla L, \tag{14}$$

$$W = W + v_t, \tag{15}$$

где:

- v_t — накопленная скорость обновления на текущей итерации;
- μ — коэффициент момента, который позволяет учитывать предыдущие обновления для сглаживания процесса;
- η — скорость обучения (learning rate);
- ∇L — градиенты функции потерь.

Момент ускоряет схождение модели и позволяет избегать осцилляций в оптимизации. Таким образом, обучение модели представляет собой процесс минимизации функции потерь, что в физической интерпретации соответствует постепенной стабилизации энергетического состояния спиновой системы.

Функция потерь

Для обучения модели используется $L2$-многоклассовая hinge loss функция. Она определяется следующим образом:

$$L = \frac{1}{N} \sum_{i=1}^{N} \sum_{j \neq y_i} \max\left(0, 1 - \hat{y}_{y_i} + \hat{y}_j\right)^2, \tag{16}$$

где $\hat{y}_{y_i}$ — предсказанная энергия для правильного класса y_i, $\hat{y}_j$ — энергия для неправильного класса j, N — размер батча.

- Функция потерь минимизируется, когда энергия правильного класса $\hat{y}_{y_i}$ значительно меньше энергий неправильных классов $\hat{y}_j$. Это можно интерпретировать как стабилизацию правильной конфигурации спинов.
- В ходе обучения система скатывается в метастабильное состояние, решающую задачу классификации

Эволюция стекла

Модель со слоями размером $[784, 256, 128, 10]$ обучалась на данных, представленных в виде спинов ($+1$ или -1). В процессе обучения входной слой, содержащий 784 спинов, обновляется, проходя через скрытые слои модели (256 и 128 спинов соответственно), и на выходном слое выводится результат — единственный спин, равный $+1$, обозначает метку класса.

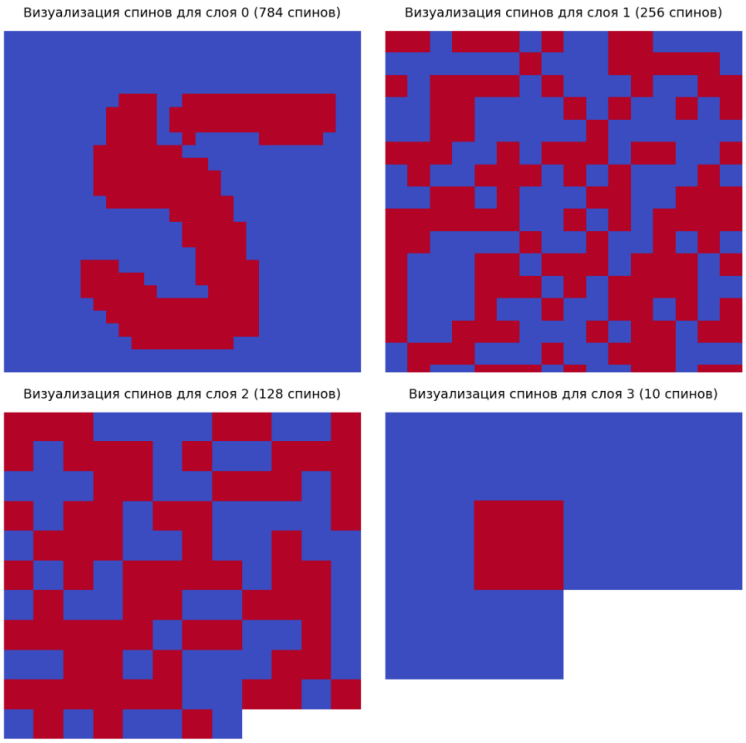

Рис. 6: Структура модели: четыре слоя размером $784, 256, 128, 10$. Входной слой проходит через скрытые слои, результирующий спин на выходе указывает метку класса.

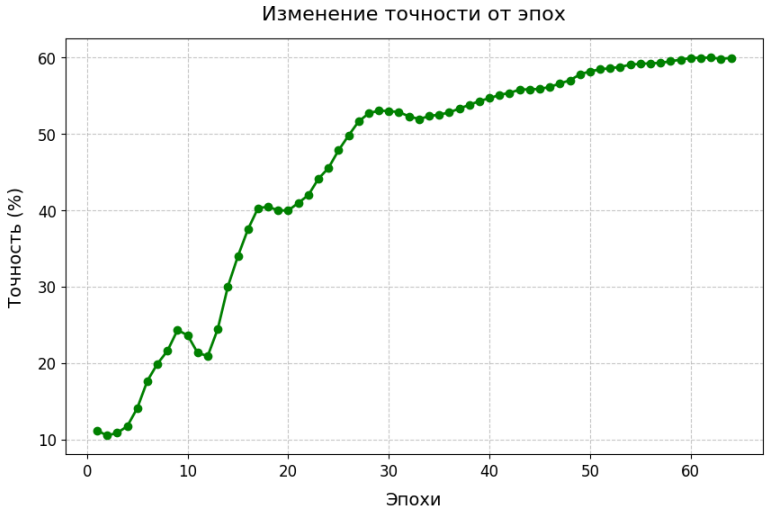

Рис. 7: Улучшение точности стекла от времени

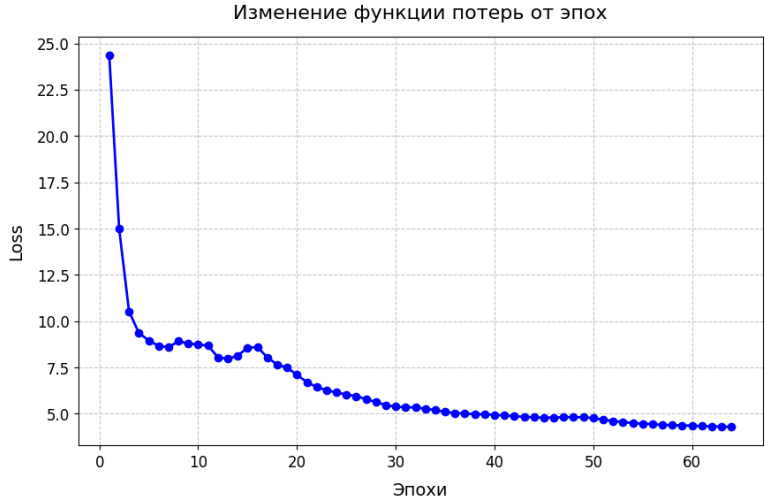

Рис. 8: Падение Loss от времени

На первых этапах обучения наблюдается быстрый рост точности, что связано с интенсивной корректировкой весов модели. По мере обучения темп роста замедляется, и после 30-й эпохи точность стабилизируется, достигая значения около 60%. Это указывает на переход модели к состоянию, близкому к глобальному минимуму функции потерь. График Loss демонстрирует быстрое уменьшение значений на первых эпохах, что свидетельствует о высокой скорости сходимости алгоритма в начале обучения. Начиная с 20-й эпохи, темп уменьшения замедляется, а функция потерь выходит на плато, что подтверждает достижение метастабильного состояния.

- Быстрое уменьшение функции потерь на первых этапах обучения связано с оптимизацией модели для грубых ошибок классификации.
- Стабилизация точности и функции потерь на поздних этапах обучения указывает на достижение системой метастабильного состояния, аналогичного фазе спинового стекла в физических системах.
- Наблюдаемая корреляция между уменьшением функции потерь и ростом точности

подтверждает, что оптимизация модели направлена на улучшение её предсказательных характеристик.

Рис. 9: Изменение энергии от времени

В процессе обучения веса адаптируются, чтобы минимизировать энергию системы, это подтверждает график.

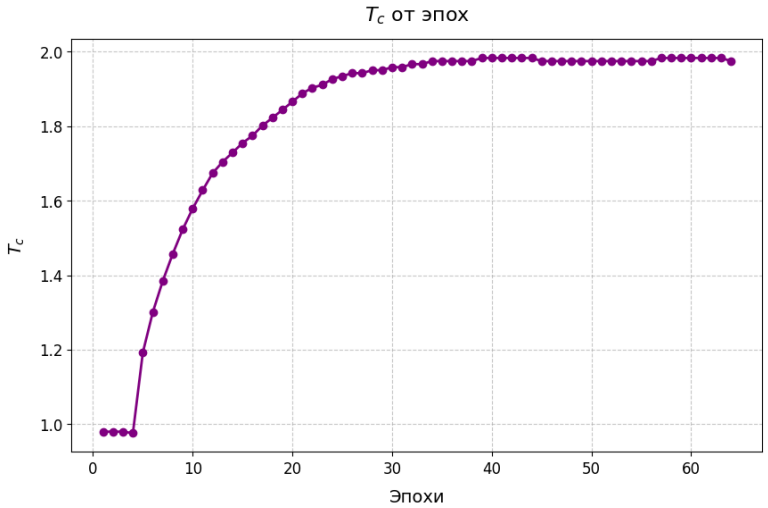

Рис. 10: Эволюция T_c от времени

Таким образом мы получили, что Tc выше 2K не поднимается.

Используя уравнения ТАП, мы численно определили температуру перехода для полученной системы спинов на протяжении всего процесса обучения. Мы обнаружили, что по мере прогресса обучения температура перехода монотонно увеличивается, демонстрируя степенной рост на протяжении некоторого времени (на этапе явного обучения). По мере обучения веса становятся более упорядоченными, что приводит к увеличению T_c. Это является усилением упорядоченности в системе спинов, что соответствует переходу в более стабильное состояние.